

Ý tưởng kế hoạch phát triển đồ án:
Curriculum-Aligned Verifiable AI Tutoring (CAVAT): A Web-based System
Combining Retrieval-Augmented Generation, Knowledge Tracing, and
Contextual Bandits

CAVAT (Hệ thống gia sư AI có thể kiểm chứng, bám sát chương trình học): Một hệ thống nền web kết hợp RAG, Knowledge Tracing và Contextual Bandits.

PHẦN 1: TỔNG QUAN - TÁC DỤNG VÀ MỤC ĐÍCH CỦA HỆ THỐNG

Mục đích tối thượng của đồ án là xây dựng một **Hệ sinh thái Trợ giảng Ảo tự chủ (Autonomous AI Tutor)** chuyên biệt cho môn Toán THPT. Đây không phải là một công cụ hỏi-đáp thông thường mà là một giải pháp giáo dục số hóa toàn diện.

- **Tác dụng thực tiễn:** Trong môi trường giáo dục hiện đại, việc có một gia sư kèm cặp 1:1 cho từng học sinh là một điều xa xỉ. Hệ thống này giải quyết trực tiếp bài toán đó bằng cách cá nhân hóa lộ trình học tập. Thông qua việc nhúng trực tiếp vào các nền tảng quản trị học tập (LMS) như Moodle, AI sẽ theo sát tiến trình, lịch sử tương tác và năng lực của từng học sinh. Khả năng hỗ trợ 24/7 ngay trong lúc các em làm bài tập giúp lấp đầy những lỗ hổng kiến thức tức thời – điều mà giáo viên đứng lớp với sĩ số đông không thể bao quát hết.
- **Giá trị học thuật:** Đồ án khẳng định năng lực làm chủ công nghệ lõi và tư duy kiến trúc hệ thống. Thay vì phụ thuộc vào các API thương mại đóng gói sẵn (tiềm ẩn rủi ro lộ lọt dữ liệu nội bộ của nhà trường và chi phí duy trì đắt đỏ), hệ thống tự chủ hoàn toàn. Việc tự triển khai, tinh chỉnh (fine-tuning) và vận hành một Mô hình Ngôn ngữ Lớn (LLM) trên hạ tầng máy chủ độc lập chứng minh sinh viên đã làm chủ được các kỹ thuật phức tạp nhất của luồng dữ liệu AI.

PHẦN 2: KIẾN TẠO MOODLE AI VÀ QUÁ TRÌNH HUẤN LUYỆN

Để tích hợp mượt mà vào Moodle mà không làm gián đoạn hệ thống hiện tại của nhà trường, đồ án sử dụng kiến trúc **Microservices** phân tách rạch ròi:

- **Frontend (Moodle Plugin/Web UI):** Giao diện tương tác được xây dựng tối ưu bằng ReactJS (sử dụng Vite và Yarn để tối đa hóa tốc độ build và hiệu năng tải trang). Thiết kế tuân thủ triết lý học thuật tối giản: sử dụng tông màu light gray dịu mắt, nút bấm SVG sắc nét, giúp học sinh duy trì sự tập trung tối đa. Khi hoạt động, module này đóng vai trò như một widget chat gọn gàng, giao tiếp với backend thông qua các API bảo mật (có cơ chế xác thực token).
- **Backend (Quá trình Training & Custom RAG):**
 - **Lỗi suy luận:** Sử dụng mô hình Qwen 2.5 - 1.5B – tối ưu cho phần cứng giới hạn nhưng sở hữu năng lực tư duy logic cực tốt.
 - **Kỹ thuật QLoRA:** Mô hình được tinh chỉnh (fine-tune) bằng phương pháp lượng tử hóa kết hợp LoRA. Tập dữ liệu huấn luyện dạng JSONL không chứa các bài giải toán rập khuôn, mà chứa các kịch bản đối thoại sư phạm. AI được huấn luyện để "thắm thấu" văn phong, cách đặt câu hỏi gợi mở và sự kiên nhẫn của một giáo viên thực thụ.
 - **Custom RAG:** Từ bỏ các framework công kênh, hệ thống sử dụng mã Python thuần kết hợp với thư viện FAISS. Quá trình chia nhỏ văn bản (chunking) được lập trình

bằng Regex để bảo toàn cấu trúc các định lý, công thức Toán học nội bộ, nạp trực tiếp vào ngữ cảnh (context) một cách siêu tốc và chính xác.

PHẦN 3: GIÁ TRỊ GIÁO DỤC - HIỆU QUẢ HỌC HIỂU CHO HỌC SINH

Sự khác biệt cốt lõi của đề án so với các công cụ quét ảnh giải toán hiện nay nằm ở triết lý giáo dục:

- Vượt qua lối mòn "Ăn liền":** Các ứng dụng thông thường trả về kết quả cuối cùng ngay lập tức, khiến học sinh sa đà vào việc chép bài, hoàn toàn không hiểu bản chất và không hình thành được nếp nghĩ tư duy.
- Phương pháp Socratic (Socratic Method):** Hệ thống được lập trình để hoạt động như một người dẫn đường. Khi nhận được câu hỏi, AI phân rã bài toán và đưa ra gợi ý từng bước.
 - Ví dụ: Thay vì giải luôn phương trình, AI sẽ hỏi: "Em đã tính được đạo hàm bậc 1 là $y' = 3x^2 - 6x$ rồi. Vậy để tìm điểm cực trị của đồ thị hàm số, bước tiếp theo ta phải xét điều kiện gì của y' ?". Phương pháp này ép buộc học sinh phải liên tục động não, xâu chuỗi kiến thức để đi đến kết quả cuối cùng.

PHẦN 4: KẾ THỪA VÀ ĐÁNH GIÁ HỆ THỐNG TIỀN ĐỀ

Dự án mới được xây dựng trên nền tảng vững chắc từ nguyên mẫu (prototype) môn Toán THCS trước đây, với sự nhìn nhận khách quan về giới hạn công nghệ:

- Điểm mạnh được kế thừa:** Đã làm chủ hoàn toàn quá trình cấu hình môi trường điện toán đám mây (Kaggle/GPU). Kỹ thuật lượng tử hóa 4-bit giúp tối ưu VRAM xuất sắc. Cơ chế RAG cơ bản đã chứng minh được khả năng ép AI bám sát định nghĩa sách giáo khoa, triệt tiêu hiện tượng "ảo giác" (hallucination).
- Điểm yếu cần đập bỏ để nâng cấp:**
 - Khuyết tật Đa phương thức:** Toán học cấp 3 phụ thuộc nặng nề vào hình học không gian và đồ thị. Hệ thống cũ (Text-based RAG) hoàn toàn "mù" trước dữ liệu hình ảnh.
 - Sai số tính toán do lượng tử hóa:** Nén mô hình xuống 4-bit giúp chạy mượt nhưng làm phát sinh sai số học trong các phép toán dài. AI tư duy bước giải đúng nhưng kết quả nhân chia lại sai.
 - Kiến trúc nguyên khối (Monolithic):** Việc sử dụng Gradio chỉ phù hợp để demo cục bộ, không thể quản lý định danh, không có khả năng mở rộng (scalability) khi hàng trăm học sinh truy cập cùng lúc.

PHẦN 5: CHIẾN LƯỢC NÂNG CẤP HỆ THỐNG SÂU SẮC

Đây là phần phô diễn sức mạnh kỹ thuật, đưa đề án đạt chuẩn đầu ra của một kỹ sư Kỹ thuật Máy tính:

- Nâng cấp Đa phương thức (Multimodal RAG):** Tích hợp thêm mô hình Vision (như Qwen2-VL) hoặc API nhận diện ký tự quang học (OCR) chuyên dụng. Hệ thống cho phép học sinh tải lên (upload) ảnh chụp đề bài viết tay hoặc sơ đồ hình học. AI sẽ bóc tách cả văn bản lẫn thuộc tính không gian của hình vẽ trước khi đưa vào luồng suy luận.
- Agentic Workflow & Code Interpreter:** Đây là công nghệ tiên tiến nhất để khắc phục điểm yếu tính toán sai của LLM. AI sẽ được nâng cấp thành một Tác tử tự trị (Agent).

- *Cơ chế hoạt động:* Khi phân tích thấy yêu cầu tính toán phức tạp (như tính tích phân, giải hệ phương trình bậc cao), AI sẽ **không** tự nhẩm kết quả. Nó sẽ tự động sinh ra một đoạn mã Python, gọi thư viện toán học **SymPy**, thực thi mã này trong một môi trường hộp cát (sandbox) an toàn trên server để lấy đáp án chuẩn xác 100% . Cuối cùng, AI dùng đáp án này để diễn giải lại cho học sinh bằng ngôn ngữ tự nhiên.

PHẦN 6: PHẢN HỒI NHƯ MỘT NGƯỜI THẦY CHUYÊN NGHIỆP

Chất lượng tương tác được kiểm soát chặt chẽ thông qua các kỹ thuật Prompt Engineering bậc cao:

- **Tác phong sư phạm:** System Prompt định hình AI với tính cách chuẩn mực, kiên nhẫn. Hệ thống được lập trình để nhận diện các câu trả lời đúng một phần của học sinh, đưa ra lời khen ngợi để khích lệ tinh thần trước khi sửa lỗi sai.
- **Trình bày chuẩn học thuật:** Mọi phản hồi toán học khi đẩy về Frontend (Moodle/Web) đều được bọc trong cú pháp chuẩn. Giao diện người dùng sẽ tích hợp các bộ render chuyên dụng, đảm bảo các ma trận, tích phân hay công thức đa tầng được hiển thị vô cùng sắc nét, tuyệt đối không vỡ cấu trúc hiển thị.

PHẦN 7: TÍNH KHẢ THI VÀ KHẢ NĂNG PHÁT TRIỂN (SCALABILITY)

- **Tính khả thi triển khai:** Backend AI được đóng gói bằng FastAPI và Docker (Containerization). Kiến trúc này cho phép nhà trường dễ dàng triển khai (deploy) thẳng lên các máy chủ nội bộ (On-premise) hoặc các dịch vụ đám mây tư nhân. Toàn bộ dữ liệu học tập và tri thức nội bộ được bảo vệ tuyệt đối, không rò rỉ ra Internet.
- **Tầm nhìn mở rộng:** Hệ thống được thiết kế với tính module hóa cao. Trong tương lai, để hỗ trợ thêm các môn khoa học tự nhiên khác như Vật Lý hay Hóa Học, quản trị viên chỉ cần cập nhật kho tri thức (Vector Database) và thay đổi System Prompt mà không cần phải can thiệp hay đập đi xây lại luồng logic AI cốt lõi.